

Prediksi URL Berbahaya Dengan Pendekatan Klasifikasi Menggunakan Algoritma NLP

Eka Maurita¹

¹ Informatika, UPN “Veteran” Jawa Timur

22081010119@student.upnjatim.ac.id

*Corresponding author email: 22081010119@student.upnjatim.ac.id

Abstrak— Penelitian ini bertujuan untuk mengembangkan metode prediksi URL berbahaya menggunakan algoritma *LightGBM* dan *XGBoost*. Dataset yang digunakan dalam penelitian ini berisi 651.191 URL yang dikategorikan sebagai *benign*, *defacement*, *phishing*, dan *malware*. Fitur-fitur penting seperti panjang URL, jumlah direktori, dan abnormalitas URL diekstraksi dan digunakan untuk melatih model. Hasil evaluasi menunjukkan bahwa kedua algoritma memiliki akurasi tinggi dalam mengklasifikasikan URL berdasarkan fitur-fitur yang diberikan. Program ini memungkinkan pengguna untuk memasukkan URL yang ingin dievaluasi dan memberikan prediksi kategori URL tersebut. Metode yang dikembangkan diharapkan dapat meningkatkan keamanan digital dengan memberikan alat prediksi yang efektif terhadap ancaman URL berbahaya

Kata kunci: *Prediksi URL, Algoritma Light GBM, XGBoost, Keamanan Internet.*

I. Pendahuluan

Di era digital saat ini, internet sudah menjadi bagian yang tidak bisa dipisahkan dari kehidupan sehari-hari. Namun dengan kemudahan akses yang diberikan oleh internet, ancaman keamanan yang semakin canggih pun bermunculan, seperti serangan phishing. Menurut (Rachmawati, 2014: 211) Phising adalah salah satu kejahatan elektronik dalam bentuk penipuan. Dimana proses phising ini bermaksud untuk menangkap informasi yang sangat sensitif seperti username, password dan detail kartu kredit dalam bentuk meniru sebagai sebuah entitas yang dapat dipercaya/legitimate organization dan biasanya berkomunikasi secara elektronik.

Metode umum yang digunakan oleh penyerang phishing adalah dengan menggunakan URL yang menyesatkan. URL adalah singkatan dari Uniform Resource Locator, yang mengacu pada cara mengidentifikasi lokasi file di internet. Secara umum, URL adalah cara untuk menemukan file di internet, baik dalam bentuk situs web, gambar, video, program perangkat lunak, atau jenis file lainnya yang dihosting di server. URL berbahaya sering kali menipu pengguna dengan menggunakan nama domain atau situs yang tampak asli, tetapi sebenarnya mengarahkan pengguna ke situs palsu yang dirancang untuk mencuri informasi pribadi mereka. Oleh karena itu, memprediksi URL berbahaya sangat penting untuk melindungi pengguna internet dari serangan phishing.

Penerapan dalam hal ini peneliti membandingkan 2 klasifikasi yaitu *XGBoost* dan *LightGBM*. Sedangkan *Light Gradient Boosting Machine (LightGBM)* merupakan sebuah metode

gradient boosting yang cepat, terdistribusi dan memiliki high-performance berdasarkan decision tree. Menurut (Ke et al., 2017) *LightGBM* merupakan salah satu metode ensemble yang melakukan agregasi terhadap prediksi dari beberapa decision tree (dengan menambahkan setiap tree).

Algoritma *XGBoost* dan *LightGBM* memiliki potensi besar dalam memprediksi URL berbahaya. Algoritma ini memungkinkan analisis mendalam untuk mengidentifikasi pola dan karakteristik URL yang mencurigakan atau berpotensi berbahaya. *XGBoost* merupakan algoritma boosting berbasis pohon keputusan yang menggabungkan sejumlah weak learner secara bertahap dengan mekanisme regularisasi, sehingga mampu meningkatkan akurasi prediksi sekaligus mengurangi risiko overfitting. Sedangkan *LightGBM* adalah algoritma peningkatan gradien yang efisien, yang mampu memproses data dalam jumlah besar dengan kecepatan tinggi dan akurasi yang baik.

Metode penelitian ini dimulai dengan pengumpulan dataset dari Kaggle yang bernama "Malicious URLs dataset", yang berisi 651.191 URL. Dataset ini terdiri dari 428.103 URL *benign* atau aman, 96.457 URL *defacement*, 94.111 URL *phishing*, dan 32.520 URL *malware*. Langkah pertama dalam pengolahan data adalah melakukan eksplorasi dan visualisasi data untuk memahami distribusi dan karakteristik URL. Dilanjutkan dengan ekstraksi fitur dari URL yang mencakup berbagai aspek seperti panjang URL, kehadiran karakter khusus, dan pola-pola tertentu dalam string URL. Fitur-fitur ini diimplementasikan melalui fungsi-fungsi khusus yang dikembangkan untuk memprediksi karakteristik mencurigakan dalam URL.

Tujuan dari penelitian ini adalah mengembangkan metode untuk memprediksi URL berbahaya menggunakan algoritma *XGBoost* dan *LightGBM*. Metode ini diharapkan mampu mengidentifikasi URL mencurigakan dengan akurasi tinggi melalui analisis fitur yang mendetail. Hasil penelitian ini diharapkan bermanfaat dalam meningkatkan keamanan internet dan melindungi informasi pribadi pengguna. Model *XGBoost* dan *LightGBM* yang telah dikembangkan kemudian dievaluasi menggunakan metrik performa seperti *confusion matrix* dan fitur penting untuk memastikan efektivitasnya dalam memprediksi URL berbahaya.

Metodologi

A. Rumusan Masalah

Penelitian ini bertujuan untuk menyelesaikan permasalahan meningkatnya ancaman keamanan digital yang berasal dari URL berbahaya seperti phishing, malware, dan defacement. Permasalahan utama yang dikaji adalah bagaimana memanfaatkan algoritma machine learning untuk mengklasifikasikan URL berdasarkan karakteristiknya sehingga dapat dibedakan antara URL aman dan URL berbahaya. Selain itu, penelitian ini juga membahas fitur-fitur apa saja yang paling berpengaruh dalam proses klasifikasi serta bagaimana perbandingan kinerja algoritma *LightGBM* dan *XGBoost* dalam memprediksi URL berbahaya secara akurat..

B. Tinjauan Literatur

Tinjauan literatur dilakukan dengan mengkaji berbagai penelitian terdahulu yang berkaitan dengan deteksi URL berbahaya menggunakan pendekatan *machine learning*. Beberapa penelitian menunjukkan bahwa algoritma berbasis decision tree seperti *LightGBM* dan *XGBoost* memiliki performa yang baik dalam menangani data berdimensi besar dan kompleks. *LightGBM* memiliki keunggulan dalam efisiensi komputasi dan kecepatan pelatihan, Sedangkan *XGBoost* memiliki keunggulan dalam kemampuan menangani data berukuran besar, performa prediksi yang tinggi, serta mekanisme regularisasi yang efektif untuk mengurangi risiko *overfitting*, sehingga mampu menghasilkan model yang lebih akurat dan stabil. Selain itu, literatur juga menekankan pentingnya *feature engineering* pada URL untuk meningkatkan akurasi model dalam mengenali pola URL berbahaya.

C. Pengumpulan Data

Pengumpulan data dalam penelitian ini dilakukan dengan menggunakan dataset publik yang diperoleh dari Kaggle, yaitu "Malicious URLs Dataset". Dataset ini berisi 651.191 data URL yang telah diklasifikasikan ke dalam empat kategori, yaitu *benign*, *defacement*, *phishing*, dan *malware*. Dataset tersebut dipilih karena memiliki jumlah data yang besar serta variasi kategori URL yang relevan dengan tujuan penelitian dalam mendeteksi ancaman keamanan berbasis URL.

D. Pengolahan Data

Tahap pengolahan data diawali dengan eksplorasi data untuk memahami struktur dan distribusi kelas URL. Selanjutnya dilakukan proses *preprocessing* yang meliputi pembersihan data, transformasi URL menjadi fitur numerik, serta normalisasi data jika diperlukan. Pada tahap ini juga dilakukan *feature engineering* dengan mengekstraksi berbagai fitur penting dari URL, seperti panjang URL, jumlah direktori, keberadaan alamat IP, abnormalitas URL, panjang hostname, dan panjang top-level domain. Proses ini bertujuan untuk menghasilkan fitur yang representatif agar model dapat mempelajari pola URL berbahaya dengan lebih baik.

E. Pemodelan

Pemodelan dalam penelitian ini menggunakan dua algoritma supervised learning, yaitu *Light GBM* dan *XGBoost*. Dataset yang telah diproses kemudian dibagi menjadi data latih dan data uji dengan rasio 80% untuk data latih dan 20% untuk data

uji menggunakan metode stratified split agar distribusi kelas tetap seimbang. Model *Light GBM* dan *XGBoost* dilatih menggunakan data latih untuk mempelajari karakteristik URL, kemudian digunakan untuk melakukan prediksi pada data uji.

F. Evaluasi Model

Evaluasi model dilakukan untuk mengukur kinerja algoritma *LightGBM* dan *XGBoost* dalam mengklasifikasikan URL. Metrik evaluasi yang digunakan meliputi *accuracy*, *precision*, *recall*, dan *F1-score*, serta *confusion matrix* untuk mengetahui tingkat kesalahan klasifikasi pada setiap kategori URL. Selain itu, dilakukan analisis *feature importance* untuk mengetahui fitur-fitur yang paling berpengaruh terhadap hasil prediksi. Hasil evaluasi dari kedua model dibandingkan untuk menentukan algoritma yang memiliki performa terbaik.

G. Alur Penelitian

Alur penelitian ini dimulai dari identifikasi masalah dan studi literatur, dilanjutkan dengan pengumpulan dataset, pengolahan dan eksplorasi data, ekstraksi fitur, pembagian data menjadi data latih dan data uji, pelatihan model *Light GBM* dan *XGBoost*, evaluasi performa model, serta analisis hasil dan penarikan kesimpulan. Alur penelitian ini disusun secara sistematis agar penelitian dapat berjalan terstruktur dan menghasilkan model prediksi URL berbahaya yang akurat dan dapat diandalkan..

II. PEMBAHASAN

III.1 Pengumpulan Data

Dataset yang digunakan dalam penelitian ini berisi 651.191 URL yang diklasifikasikan ke dalam empat kategori: *benign*, *defacement*, *phishing*, dan *malware*.

Tabel 1 – Klasifikasi kategori URL

Kategori	Definisi
<i>Benign</i>	URL tersebut aman dan tidak berbahaya.
<i>Defacement</i>	URL tersebut mengarah ke situs web yang telah diretas.
<i>Phising</i>	URL tersebut mengarah ke situs web palsu yang dibuat untuk meniru situs web resmi.
<i>Malware</i>	URL tersebut mengarah ke situs web yang mengandung malware.

Tabel 2 – Dataset

Kategori	Jumlah URL
<i>Benign</i>	428.103
<i>Defacement</i>	96.457
<i>Phising</i>	94.111
<i>Malware</i>	32.520
Total	651.191

3

III.5 Analisis Data Eksploratif

Analisis Data Eksploratif adalah proses penting untuk memahami dan memvisualisasikan kumpulan data dan menemukan pola, anomali, dan hubungan antar variabel sebelum membangun model prediktif. Penelitian ini menggunakan seaborn untuk visualisasi distribusi fitur berdasarkan tipe URL. Berikut kesimpulan dari hasil distribusi:

Tabel 3 – Hasil distribusi

Distribusi	Kesimpulan
<i>Use of IP</i>	URL yang menggunakan alamat IP langsung lebih sering tergolong “aman” dibandingkan kategori lainnya.
Abnormal URL	Mayoritas URL <i>benign</i> tidak memiliki sifat abnormal. Dalam kategori <i>phishing</i> , ada beberapa URL yang memiliki sifat abnormal, sedangkan <i>defacement</i> dan <i>malware</i> hanya memiliki URL abnormal.
Google Index	Semua data URL telah terindeks oleh Google.
<i>Short URL</i>	URL pendek lebih sedikit jumlahnya, terutama pada kategori <i>phishing</i> dan <i>benign</i> . URL yang tidak pendek mendominasi di semua kategori.
<i>Suspicious URL</i>	Mayoritas URL dari semua kategori tidak mencurigakan. URL mencurigakan hanya terdapat dalam jumlah yang sangat sedikit.
<i>Count of [.] dot</i>	<i>Malware</i> memiliki median dot yang sedikit lebih tinggi dibandingkan kategori lainnya. Mayoritas URL memiliki nilai dot yang relatif rendah dengan beberapa <i>outliers</i> .
<i>Count of (www)</i>	Mayoritas URL dari semua kategori memiliki nilai <i>www</i> yang sangat rendah. Kategori <i>defacement</i> memiliki distribusi yang lebih bervariasi.
<i>Count @</i>	Penggunaan simbol @ dalam URL adalah kejadian yang sangat jarang di seluruh kategori, dengan satu <i>outlier</i> di masing-masing kategori.
<i>Count dir</i>	Setiap kategori URL memiliki rentang nilai <i>dir</i> yang cukup luas, dengan kategori <i>benign</i> dan <i>phishing</i> menunjukkan jumlah <i>outliers</i> yang lebih banyak. <i>Malware</i> memiliki median <i>dir</i> yang sedikit lebih tinggi dibandingkan kategori lainnya.

<i>Hostname Length</i>	Kategori <i>phishing</i> memiliki variasi <i>hostname_length</i> yang paling tinggi dengan banyak <i>outliers</i> . Kategori <i>benign</i> memiliki mayoritas nilai <i>hostname_length</i> yang sangat rendah. Kategori <i>defacement</i> dan <i>malware</i> memiliki distribusi yang mirip.
<i>First Directory Length</i>	Kategori <i>benign</i> dan <i>malware</i> menunjukkan variasi <i>fd_length</i> yang lebih tinggi. Kategori <i>phishing</i> dan <i>defacement</i> memiliki distribusi yang lebih terfokus dengan nilai median yang lebih rendah.
<i>Top-Level Domain Length</i>	Panjang TLD untuk situs <i>phishing</i> cenderung lebih bervariasi dan lebih panjang dibandingkan dengan jenis situs lainnya. Situs <i>benign</i> memiliki panjang TLD yang sangat pendek dan konsisten. Situs <i>defacement</i> dan <i>malware</i> memiliki distribusi panjang TLD yang mirip.

III. 6 Persiapan Data (Split Data)

Persiapan data memastikan model pembelajaran mesin dapat belajar dengan efektif dari data yang ada dan memberikan hasil yang akurat dalam mengidentifikasi URL berbahaya. Persiapan data dilakukan dengan membagi *dataset* menjadi data pelatihan dan data pengujian. Tabel berikut menunjukkan distribusi data setelah pembagian:

Tabel 4 – Distribusi data setelah pembagian

Kategori	Data Pelatihan	Data Pengujian
<i>Benign</i>	342.482	85.621
<i>Defacement</i>	77.166	19.291
<i>Phising</i>	75.289	18.822
<i>Malware</i>	26.016	6.504
Total	520.953	130.238

Berdasarkan **Tabel 4**, Pembagian ini dilakukan dengan rasio 80% untuk data pelatihan dan 20% untuk data pengujian. Dengan langkah-langkah persiapan data, *dataset* siap digunakan untuk melatih model *XGBoost* dan *LightGBM* dalam memprediksi URL berbahaya dengan akurasi yang tinggi.

III. 7 Evaluasi Model

Setelah melalui proses pelatihan menggunakan algoritma *XGBoost* dan *LightGBM*, model-model ini dievaluasi menggunakan data pengujian yang telah disiapkan. Hasil dari evaluasi ini memberikan gambaran mengenai kinerja masing-masing model dalam memprediksi URL berbahaya.

a). *LightGBM*


Hasil evaluasi dari model *LightGBM* juga menunjukkan performa yang kompetitif. Dengan akurasi sebesar 99.1%,

model ini sedikit lebih rendah dibandingkan *XGBoost*, namun tetap memberikan hasil yang memuaskan. Tabel berikut menunjukkan evaluasi dari model *LightGBM*:

	precision	recall	f1-score	support
benign	1.00	1.00	1.00	19920
defacement	0.98	0.99	0.99	5005
phishing	0.96	0.84	0.89	653
malware	0.95	0.94	0.95	1629
accuracy			0.99	27207
macro avg	0.97	0.94	0.96	27207
weighted avg	0.99	0.99	0.99	27207
accuracy:	0.991			

Gambar 7. Hasil Akurasi *LightGBM*


Berdasarkan **Gambar 7**, 0.991 menunjukkan bahwa model *LightGBM* mempunyai kinerja yang sangat tinggi dalam mengklasifikasikan beberapa jenis serangan. Model ini menunjukkan performa terbaiknya pada kategori “benign” dengan semua score sebesar 1.00, sedangkan untuk kelas “defacement” menunjukkan hasil *precision* 0.98, *recall* 0.99, dan *f1-score* 0.99. Namun, pada kelas “phishing” model memiliki *recall* yang lebih rendah yaitu 0.84, meskipun *precision*-nya tetap tinggi pada 0.96, menghasilkan *f1-score* 0.89. Kinerja pada kategori “malware” juga sangat baik dengan *precision* 0.95, *recall* 0.94, dan *f1-score* 0.95. Secara keseluruhan, model ini menunjukkan kemampuan klasifikasi yang sangat akurat dalam memprediksi segala jenis serangan.



Gambar 8. Confusion Matrix *LightGBM*

Berdasarkan **Gambar 8**, Model menunjukkan akurasi tinggi dalam mengidentifikasi *URL benign*, dengan 19.907 prediksi benar dan hanya sedikit kesalahan klasifikasi. Untuk *URL defacement*, model berhasil mengidentifikasi 4.974 kasus dengan tepat, meskipun ada beberapa kesalahan terutama dalam mengklasifikasikan *malware* sebagai *defacement*. Prediksi *phishing* relatif akurat dengan 549 kasus teridentifikasi benar, namun terdapat beberapa kesalahan klasifikasi terutama dengan *malware*. Dalam kategori *malware*, model berhasil mengidentifikasi 1.539 kasus dengan benar, tetapi juga melakukan beberapa kesalahan klasifikasi, terutama dengan

phishing. Secara keseluruhan, model menunjukkan performa yang kuat, khususnya untuk kategori *benign* dan *defacement*, namun masih ada ruang untuk peningkatan dalam membedakan antara *phishing* dan *malware* yang merupakan tantangan umum dalam klasifikasi *URL* berbahaya.



Gambar 9. Grafik Fitur Penting *LightGBM*

Berdasarkan **Gambar 9**, Menunjukkan bahwa tingkat pentingnya fitur-fitur berdasarkan kontribusi terhadap kinerja model *LightGBM* yang digunakan untuk mengklasifikasi serangan. Fitur dengan kontribusi terbesar adalah “fd_length”, “hostname_length”, dan “url_length” yang menunjukkan jumlah digit, direktori, dan huruf dalam URL. Fitur seperti “count-https,” “count-www,” dan “sus_url” juga memberikan kontribusi yang penting yaitu mencerminkan aspek-aspek keamanan dan struktur URL yang relevan. Fitur-fitur dengan kontribusi lebih rendah seperti “abnormal_url,” “use_of_ip,”

dan “count_embed_domain” masih memiliki peran tetapi tidak sekuat fitur-fitur utama. Secara keseluruhan, grafik ini membantu memahami faktor-faktor kunci yang digunakan oleh model untuk mengidentifikasi jenis serangan dengan akurasi yang tinggi.

b) *XGBoost Classifier*


Pada tahap ini, model *XGboost Classifier* digunakan untuk memprediksi url berbahaya dengan melatih model menggunakan data yang mencakup berbagai jenis url, seperti url yang aman (benign) dan url yang berbahaya (phishing, malware, dan defacement). Dengan memanfaatkan fitur-fitur dari url tersebut, *XGboost* dapat belajar mengenai pola dan karakteristik yang dapat membedakan url berbahaya dan aman. Melalui proses boosting dimana setiap pohon keputusan yang baru akan memperbaiki pohon kesalahan pada pohon sebelumnya, *XGboost* juga menciptakan model yang mengklasifikasikan url dengan sangat akurat.

	precision	recall	f1-score	support
benign	1.00	1.00	1.00	19920
defacement	0.98	1.00	0.99	5005
phishing	0.97	0.85	0.90	653
malware	0.96	0.95	0.95	1629
accuracy			0.99	27207
macro avg	0.98	0.95	0.96	27207
weighted avg	0.99	0.99	0.99	27207

accuracy: 0.992

Gambar 10. Hasil Akurasi XGBoost

Dari hasil akurasi diatas yaitu 0.992 menunjukkan bahwa model XGboost Classifier memiliki performa yang sangat baik dalam mengklasifikasikan data. Secara rinci, model ini memiliki precision, recall, dan f1-score sebesar 1.00 untuk kategori 'benign', yang berarti tidak ada kesalahan dalam mendeteksi aktivitas yang tidak berbahaya. Untuk kategori 'defacement', model mencapai precision sebesar 0.98, recall sebesar 1.00, dan f1-score sebesar 0.99, menunjukkan kemampuan tinggi dalam mendeteksi serangan defacement dengan sedikit kesalahan positif. Untuk kategori 'phishing', precision adalah 0.97, recall 0.85, dan f1-score 0.90, yang menunjukkan bahwa model cukup baik dalam mendeteksi serangan phishing, meskipun ada beberapa serangan yang terlewat. Sedangkan untuk kategori 'malware', precision adalah 0.96, recall 0.95, dan f1-score 0.95, yang juga menunjukkan performa tinggi dalam mendeteksi malware. Nilai macro average dan weighted average dari precision, recall, dan f1-score juga mendukung performa tinggi dari model ini.



Gambar 11. Grafik Fitur Penting XGBoost

Dari grafik diatas menunjukkan bahwa pentingnya berbagai fitur dalam model XGboost. Fitur hostname_length memiliki kontribusi terbesar, menunjukkan bahwa panjang hostname adalah indikator penting dalam mendeteksi URL mencurigakan. Fitur lain yang signifikan termasuk count_dir (jumlah direktori dalam URL), count-www (jumlah kemunculan "www"), count% (jumlah tanda persentase), tld_length (panjang top-level domain), dan url_length (panjang keseluruhan URL). Fitur-fitur ini membantu model mengidentifikasi pola yang mungkin

menunjukkan URL phishing atau berbahaya, dengan fitur yang lebih penting memberikan kontribusi lebih besar terhadap performa model.

III.8 Hasil Prediksi

Dalam tahap prediksi, program ini menggunakan model algoritma *Random Forest* dan *LightGBM* yang telah dilatih untuk memprediksi status URL berdasarkan fitur-fitur yang telah dikumpulkan. Model ini mengkategorikan URL sebagai "benign" (aman), "defacement", "phishing", atau "malware". Dalam melakukan prediksi, pengguna dapat memasukkan URL yang ingin dievaluasi. Program ini akan mengekstraksi fitur-fitur relevan dari URL tersebut, seperti panjang URL, keberadaan alamat IP, jumlah subdomain, dan lain-lain.

Fitur-fitur ini menjadi input untuk model *Random Forest* dan *LightGBM* yang sudah dilatih sebelumnya. Model akan melakukan klasifikasi pada URL tersebut berdasarkan pola dan karakteristik yang telah dipelajari selama tahap pelatihan. Hasilnya menunjukkan apakah URL tersebut diprediksi sebagai "benign", "defacement", "phishing", atau "malware".

Pada penelitian ini, kami mencoba beberapa URL sebagai uji coba program. Hasil program tersebut menampilkan seperti berikut:

```
urls = ['icoinhub.co']
for url in urls:
    print(get_prediction_from_url(url))

[LightGBM] [Warning] Unknown parameter: silent
MALWARE
```

Gambar 12. Hasil uji coba pada icoinhub.co

Berdasarkan Gambar 12. Program memprediksi bahwa URL "icoinhub.co" merupakan URL yang mengandung malware.

```
urls = ['instagram.com/wayzzn']
for url in urls:
    print(get_prediction_from_url(url))

[LightGBM] [Warning] Unknown parameter: silent
SAFE
```

Gambar 13. Hasil uji coba pada instagram.com/wayzzn

Berdasarkan Gambar 13. Program memprediksi bahwa URL "instagram.com/wayzzn" merupakan URL yang termasuk

kategori benign atau aman untuk diakses.

```
urls = ['icoinhub.co', 'instagram.com/wayzzn']
for url in urls:
    print(get_prediction_from_url(url))

[LightGBM] [warning] Unknown parameter: silent
MALWARE
[LightGBM] [warning] Unknown parameter: silent
SAFE
```

Gambar 14. Hasil uji coba pada dua domain

Berdasarkan **Gambar 14**, Program dapat memprediksi lebih dari satu URL secara bersamaan. Setelah melakukan uji coba tersebut, dapat disimpulkan jika suatu URL diprediksi sebagai "phishing", maka hasilnya menunjukkan bahwa URL tersebut berpotensi sebagai upaya phishing yang mencoba menipu pengguna dan mencuri informasi sensitif. Sebaliknya juga, apabila program menunjukkan bahwa URL tersebut "benign", maka URL tersebut aman untuk diakses atau dikunjungi. Pengguna dapat menggunakan informasi ini untuk menghindari mengunjungi URL tersebut dan melindungi diri dari ancaman keamanan. Fungsi prediksi ini memberikan cara yang efisien untuk mengevaluasi keamanan berbagai URL berdasarkan fitur-fitur tertentu yang telah ditentukan sebelumnya, memungkinkan pengguna untuk memprediksi dan menghindari ancaman keamanan secara proaktif.

III. Kesimpulan

Penelitian ini mengembangkan metode prediksi URL berbahaya menggunakan algoritma *LightGBM* dan *XGBoost*. Fitur URL seperti panjang, *hostname*, dan jumlah direktori digunakan untuk klasifikasi menjadi empat kategori: *benign*, *defacement*, *phishing*, dan *malware*. Dataset dari Kaggle berisi 651.191 URL digunakan untuk melatih model. Hasil penelitian menunjukkan bahwa model yang dibangun dapat membedakan URL yang sah dan berbahaya dengan akurasi yang signifikan, sehingga dapat lebih melindungi pengguna internet dari serangan phishing dan ancaman keamanan digital lainnya. Program memungkinkan pengguna memasukkan URL untuk dievaluasi, memberikan prediksi kategori keamanannya. Penelitian ini membuktikan efektivitas *LightGBM* dan *XGBoost* dalam memprediksi URL berbahaya, meningkatkan keamanan internet dan memberikan alat perlindungan bagi pengguna dari ancaman phishing dan malware.

REFERENSI

- [1] D. Rachmawati, "Phising sebagai salah satu bentuk ancaman dalam dunia cyber," *Jurnal Saintkom*, vol. 13, no. 3, p. 211, 2014.
- [2] A. Hartati, I. Zain, dan B. S. Suprih Ulama, "Analisis CART (Classification and Regression)," *Jurnal Sains dan Seni ITS*, vol. 1, no. 1, pp. 101–105, 2012.

- [3] G. Ke *et al.*, "LightGBM: A highly efficient gradient boosting decision tree," Microsoft Research, Dec. 2017. [Online]. Tersedia: <https://www.microsoft.com/en-us/research/publication/lightgbm-a-highly-efficient-gradient-boosting-decision-tree/>
- [4] M. R. Adrian, M. P. Putra, M. H. Rafialdy, dan N. A. Rakhmawati, "Perbandingan metode klasifikasi Random Forest dan SVM pada analisis sentimen PSBB," *Jurnal Informatika Upgris*, vol. 7, no. 1, 2021.
- [5] M. J. Setiawan, B. Nugroho, dan A. P. Sari, "Klasifikasi penyakit daun tanaman menggunakan algoritma CNN dan Random Forest," *Teknologi: Jurnal Ilmiah Sistem Informasi*, vol. 13, no. 2, pp. 12–18, 2023.
- [6] P. S. Rizky, R. H. Hirzi, dan U. Hidayaturohman, "Perbandingan metode LightGBM dan XGBoost dalam menangani data dengan kelas tidak seimbang," *Jurnal Statistika: Jurnal Ilmiah Teori dan Aplikasi Statistika*, vol. 15, no. 2, pp. 228–236, 2022.
- [7] G. N. Kurniawati, "Algoritma Machine Learning yang harus kamu pelajari di tahun 2021," Jan. 4, 2021. [Online]. Tersedia: <https://dqqlab.id/algoritma-machine-learning-yang-perlu-dipelajari>
- [8] R. N. Suropto, "Teknik pre-processing dan classification dalam data science," Aug. 26, 2022. [Online]. Tersedia: <https://mie.binus.ac.id/2022/08/26/teknik-pre-processing-dan-classification-dalam-data-science/>
- [9] R. R. Rachmadi, A. Sudarsono, dan T. B. Santoso, "Implementasi metode LightGBM untuk klasifikasi kondisi abnormal pada pengemudi sepeda motor berbasis sensor smartphone," *Jurnal Komputer Terapan*, vol. 7, no. 2, pp. 218–227, 2021.
- [10] I. Lestari, M. Akbar, dan B. Intan, "Perbandingan algoritma machine learning untuk klasifikasi Amenorrhea," *Journal of Computer and Information Systems Ampera*, vol. 4, no. 1, pp. 32–43, 2023.
- [11] D. P. Langgeni, Z. A. Baizal, dan Y. F. AW, "Clustering artikel berita berbahasa Indonesia menggunakan unsupervised feature selection," dalam *Seminar Nasional Informatika (SEMNASIF)*, vol. 1, no. 4, Jul. 2015.
- [12] A. S. Gillis, "Definition data splitting," 2022. [Online]. Tersedia: <https://www.techtarget.com/searchenterpriseai/definition/data-splitting>
- [13] J. Jamaludin, C. Rozikin, dan A. S. Y. Irawan, "Klasifikasi jenis buah mangga dengan metode Backpropagation," *Techné: Jurnal Ilmiah Elektroteknika*, vol. 20, no. 1, pp. 1–12, 2021.
- [14] A. Primajaya dan B. N. Sari, "Random forest algorithm for prediction of precipitation," 2018.
- [15] E. Febrianoro, E. Setyati, dan J. Santoso, "Pemodelan prediksi kuantitas penjualan mainan menggunakan LightGBM," *SMARTICS Journal*, vol. 9, no. 1, pp. 7–13, 2023.
- [16] K. S. Nugroho, "Confusion matrix untuk evaluasi model pada supervised learning," Nov. 13, 2019. [Online]. Tersedia: <https://ksnugroho.medium.com/confusion-matrix-untuk-evaluasi-model-pada-unsupervised-machine-learning-bc4b1ae9ae3f>
- [17] R. Parlika, S. I. Pradika, A. M. Hakim, dan K. R. N. M., "Analisis sentimen Twitter terhadap Bitcoin dan Cryptocurrency berbasis Python TextBlob," *Jurnal Ilmiah Teknologi Informasi dan Robotika*, vol. 2, no. 2, pp. 33–37, 2020.
- [18] M. Waskom, *Seaborn: Statistical Data Visualization*, 2018. [Online]. Tersedia: <https://seaborn.pydata.org/>
- [19] Kaggle, "Malicious URLs dataset," [Online]. Tersedia: <https://www.kaggle.com/datasets/sid321axn/malicious-urls-dataset>